1. METODOLOGÍA DE LA PRÁCTICA

La práctica se realiza en equipos de tres personas. Cada equipo llevará a cabo una propuesta, y desarrollo asociado, de un sistema de integración de información para un supuesto específico. La práctica se organiza en una secuencia de HITOS, en los cuales habrá que realizar una entrega. Esta entrega será revisada por los docentes de la asignatura y habrá una sesión de revisión de la propuesta entregada con los docentes de la asignatura. Durante esta sesión el equipo recibirá retroalimentación para realizar mejoras que contribuyan a la calidad de la propuesta final. Tras la última entrega habrá una sesión de defensa del proyecto entregado, en la cual cada equipo dispondrá de un tiempo para la presentación de su proyecto. Los HITOS son los que se muestran en la tabla 1:

HITO	DESCRIPCIÓN	FECHA
HITO 1	Descripción de las Fuentes. Mappings GAV y LAV. Implementación BD.	25 de marzo
HITO 2	Acceso a una Fuente Usando Scraping.	15 de abril
HITO 3	Acceso a una Fuente Usando SPARQL.	29 de abril
HITO 4	Diseño e Implementación del Sistema Integrador.	18 de mayo
HITO DEFENSA	Defensa del proyecto.	22 de mayo

Tabla 1. Hitos de la práctica.

2. DESCRIPCIÓN Y ENTREGABLES DE CADA HITO

HITO 1: DESCRIPCIÓN DE LAS FUENTES. MAPPINGS GAV Y LAV. IMPLEMENTACIÓN BD.

Se entregarán las propuestas de abstracciones (esquemas) para el mediador y para las fuentes de datos. Se entregarán los mapping GAV y LAV de las fuentes, acorde con los esquemas relacionales propuestos.

Se crearán bases de datos relacionales en las máquinas virtuales proporcionadas, ajustadas a los esquemas relacionales propuestos como equivalentes para cada fuente y para el mediador. Se tienen que proponer al menos tres fuentes y un mediador, esto es, habrá al menos cuatro bases de datos. Además, se propondrán tres consultas que necesiten acceder a más de una fuente. Para cada consulta se proporcionará: enunciado en lenguaje natural, consulta SQL de entrada al mediador, reformulación de la consulta utilizando los mapping GAV, reformulación de la consulta utilizando los mapping LAV.

También se desarrollará un programa sencillo que accederá a dos bases de datos en distintos servidores y agregará información procedente de ambas. El lenguaje de programación es de libre elección.

En esta entrega se proporcionarán los ficheros, cuyos nombres se ajustarán a lo indicado en la tarea de entrega:

1) Informe en texto libre, que debe contener como mínimo la siguiente información:
    a. **Nombre y Apellidos** de las personas que entregan la práctica (y su grupo).
    b. **Tema/Supuesto elegido**: Breve descripción del tema elegido para el sistema integrador y del tipo de información que proporciona a las personas que lo utilizan. Entre esta información se incluirá la descripción en lenguaje natural de las tres consultas mencionadas anteriormente.
    c. **Esquemas del mediador:** Se incluirá la especificación de los esquemas, el diccionario de datos que explica cada tabla y sus atributos, y una breve descripción del tipo de información que contiene. Además, se mostrará una "captura" de una instancia donde se habrán insertado dos elementos de ejemplo en cada tabla. Se recomienda que estos ejemplos se recojan o construyan a partir de datos que se hayan encontrado en las fuentes de datos que se utilizarán en la práctica.
    d. **Formulación SQL** de las tres consultas.
    e. **Abstracciones de las fuentes de datos**: Para cada fuente de datos se hará el mismo trabajo que para el mediador, incluyendo el mismo tipo de información.
    f. **Descripciones de las fuentes de datos. Descripciones GAV. Descripciones LAV.** Para cada mapping se incluirá:
        i. Formulación inicial. Cada una de ellas se etiquetará con un identificador o marca único que permita referirse a ella posteriormente sin ambigüedad. Por ejemplo, G1, G2… L1, L2…
        ii. Descripción. En cada mapping debe explicarse la correspondencia establecida entre los atributos, y el motivo de la presencia de cada átomo.
        iii. Simplificación. Si se ha realizado alguna simplificación, se explicará el proceso seguido y el resultado final del mismo modo que se ha hecho con la formulación inicial. En caso de no haberse simplificado, se justificará por qué no se ha hecho.
    g. **Reformulación de las consultas**. Reescritura GAV. Reescritura LAV. Se aplicarán los algoritmos vistos en clase para reformular las consultas. Al menos en una reescritura GAV y una reescritura LAV se explicará el proceso seguido hasta llegar a la formulación final.
2) Scripts sql con la creación de cada una de las bases de datos.
3) Programa desarrollado.

HITO 2: ACCESO A UNA FUENTE USANDO SCRAPING.

En esta etapa se extraerá de alguna de las fuentes web planteadas en la práctica la información de interés. Para ello se utilizará la herramienta de scraping disponibles para su uso libre, o se implementará un programa que lo haga directamente. El informe correspondiente describirá adecuadamente el proceso seguido.

En esta entrega se proporcionarán los ficheros, cuyos nombres se ajustarán a lo indicado en la tarea de entrega:

1) Informe extendido con la documentación relativa a este hito.
2) Programa desarrollado o plantillas utilizadas para el scraping.
3) Ficheros (csv o de texto) resultado del scraping, listos para insertarse en las bases de datos relacionales que se han creado en la máquina virtual.

HITO 3: ACCESO A UNA FUENTE USANDO SPARQL.

En esta etapa se extraerá de las fuentes para SPARQL planteadas en la práctica la información de interés. Se entregarán las consultas, los resultados de su ejecución, y un informe donde se detallará la relación de las consultas SPARQL realizadas con los mapping propuestos en el Hito 1.

En esta entrega se proporcionarán los ficheros, cuyos nombres se ajustarán a lo indicado en la tarea de entrega:

1) Informe extendido con la documentación relativa a este hito.
2) Ficheros con los resultados de la ejecución de las consultas, listos para insertarse en las bases de datos relacionales que se han creado en la máquina virtual.

HITO 4: DISEÑO E IMPLEMENTACIÓN DEL SISTEMA INTEGRADOR.

En este hito se entregarán tanto los productos creados como el informe correspondiente a la solución definitiva (informe extendido y corregido sobre el que se ha ido trabajando). En esta solución se habrá implementado un mediador que resolverá las cuestiones planteadas inicialmente en la práctica, consultando las fuentes de datos.

La entrega de los artefactos utilizados (scripts, software, otros) así como del informe definitivo es obligatoria. No es necesario entregar la presentación en esta tarea. Habrá una tarea específica para hacerlo. Para el informe se entregará un fichero pdf, cuyo nombre será PracticaSAIIGrupoX.pdf, donde X se corresponde con el número de cada grupo.

En este informe se indicará como mínimo:

- Modelo de integración elegido y razones que sustentan la idoneidad de esta decisión.
- Representación gráfica donde se habrán representado el mediador, las fuentes de datos y cualquier otro elemento necesario para llevar a buen término la implementación de esta propuesta.
- Descripción de cada elemento: tipo de elemento, función en el sistema, decisiones relevantes para su diseño.
- Retos de integración que se han encontrado durante la práctica, así como las soluciones aplicadas para resolverlos. Se relacionarán con los problemas de integración que se han visto en la asignatura.

HITO DEFENSA: DEFENSAS DE PRÁCTICAS.

Cada grupo dispondrá de un tiempo máximo de 10 minutos para hacer una presentación de su práctica. Todos los grupos asistirán a la defensa de los demás. Se recomienda preparar cuidadosamente esta presentación (ver más abajo algunas indicaciones sobre criterios de calificación) y apoyarse en una presentación, la cual se puede entregar a través de una tarea asociada a la defensa de la práctica.

3. RÚBRICA DE EVALUACIÓN PARA EL TRABAJO PRÁCTICO DE LA ASIGNATURA

Los siguientes criterios serán utilizados en la evaluación de las entregas, allí donde corresponda:

- Dificultad del problema planteado: heterogeneidad de las fuentes, dificultad de las consultas, complejidad de los mappings...

- Calidad de las soluciones técnicas adoptadas: descripciones de las fuentes GAV y LAV, desdoblamientos y reescrituras de las consultas, arquitectura del sistema, software desarrollado…

- Capacidad para defender la idoneidad de estas soluciones: Para determinados tipos de problema existen varias soluciones posibles; se trata de defender por qué se ha elegido una de ellas.

- Capacidad para enmarcar estas soluciones en los temas tratados durante el desarrollo de la asignatura: En particular se debe prestar atención a la correspondencia entre el código desarrollado y las soluciones defendidas en el informe, que siempre habrán de enmarcarse en alguno de los tipos de solución vistos en la asignatura. Es muy importante ser capaz de defender cómo se han llevado a la práctica los mappings propuestos en las descripciones de las fuentes, o cómo se han resuelto las consultas (plan de ejecución, otros que puedan ser de interés).

- Calidad de los informes presentados (presentación, redacción, organización, claridad, utilización de referencias, explicaciones...)

- Calidad de las defensas (claridad, capacidad para destacar los aspectos más relevantes del trabajo realizado, organización temporal y de la presentación, calidad de la presentación o soportes utilizados...)

- Evolución en la preparación de la práctica a lo largo de la asignatura

Este listado no implica la exclusión de cualquier otro criterio que resulte procedente en la evaluación de la asignatura.

Como referencia, la calidad de las soluciones entregadas y la capacidad para enmarcarlas en la asignatura tienen un peso similar. La calidad de los informes y las defensas y evolución acaparan entre un 25% y un 30% de la nota final de la práctica.

4. ENUNCIADOS

...